Flow Matching 生成模型的定性问题研究

从 Fokker–Planck 力场确定性到子系统分割策略
——大四上半学期从 flow matching 方法研究离开的理由

[夏伟杰]
University of Michigan, Ann Arbor

2026 年 4 月 21 日

摘要

本报告探讨 Flow Matching（以下简称 FM）生成模型中一个被 FID 指标所掩盖的定性问题：由于 FM 所构造的是**确定性力场**，当目标数据域方差过大时，单一力场难以融合整个数据集的结构特征，从而在生成人脸、人体关节等具有精细结构的样本时产生**结构不连续**的畸变（俗称”鬼脸”与关节抖动）。本报告从 Fokker–Planck 方程的吉布斯自由能形式出发，在理论上对比 FM 与 DDPM 的动力学差异，指出 FM 等价于去掉熵变项的概率连续性方程；进而分析**”均值对均值”**机制下两类模型神经网络的记忆结构差异，论证了力场确定性的代价；最后给出基于缩小数据集与**子系统分割**的实验验证方案，并报告了在 CelebA 数据集上的初步结果。

目录

1 引言 **2**

2 Flow Matching 的定性问题 **2**

2.1 从 DDPM 的前向与后向公式说起 2
2.2 从 Fokker–Planck 方程看 FM 与 Diffusion 的统一 3
2.3 ”均值对均值”：两类模型神经网络记忆结构的差异 4
2.4 力场确定性的代价：方差控制问题 5
2.5 实验验证 6
2.6 子系统分割：方差控制的策略推广 7

3 结论 **7**

1 引言

Flow Matching [1] 是近两年生成模型领域快速发展的一条技术路线。相比于基于随机微分方程（SDE）的扩散模型（如 DDPM [2]），FM 直接通过学习一个确定性的向量场 $\boldsymbol{v}_t(\boldsymbol{x})$，将源分布沿常微分方程（ODE）演化到目标分布。确定性带来了几个工程上的优势：采样路径可控、推理速度快、训练通道相对简单。

然而，在使用 FID [4] 作为唯一评估指标时，一些重要的定性问题会被平均化的分数所掩盖。本报告的核心论点是：

> **FID 无法替代对生成样本的定性考察——特别是对于人脸、人体关节等具有精细结构的目标域，力场确定性与数据集方差之间存在根本的张力。**

换句话说，当我们仅依赖 FID 去监督训练时，即便 FID 数值下降，模型仍可能生成大量结构不连续的”鬼脸”样本，这是单纯的分布距离度量无法揭示的问题。

本报告按如下结构展开。第 section 2 节是主体部分，先从 DDPM 的标准公式出发（section 2.1），然后借助 Fokker–Planck 方程把 FM 与 Diffusion 放到同一个数学框架下比较（section 2.2），接着通过”均值对均值”的典型例子说明两者神经网络的记忆结构（section 2.3），分析力场确定性带来的方差问题（section 2.4），并给出实验验证（section 2.5）与子系统分割的改进策略（section 2.6）。

2 Flow Matching 的定性问题

2.1 从 DDPM 的前向与后向公式说起

为了后文的对比，我们先回顾 DDPM 的基本公式。设 $\boldsymbol{x}_0$ 为数据样本，$\boldsymbol{x}_T$ 为近似高斯噪声。DDPM 的前向过程将 $\boldsymbol{x}_0$ 通过一条离散马尔可夫链逐步加噪，可直接推出任意时刻 t 的边缘分布：

$$q(\boldsymbol{x}_t \mid \boldsymbol{x}_0) = \mathcal{N}\big(\boldsymbol{x}_t;\, \sqrt{\bar{\alpha}_t}\,\boldsymbol{x}_0,\, (1-\bar{\alpha}_t)\boldsymbol{I}\big)\,. \tag{1}$$

而后向的一步条件分布为：

$$q(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, \boldsymbol{x}_0) = \mathcal{N}\Big(\boldsymbol{x}_{t-1};\, \tilde{\boldsymbol{\mu}}_t(\boldsymbol{x}_t, \boldsymbol{x}_0),\, \tilde{\beta}_t \boldsymbol{I}\Big)\,, \tag{2}$$

$$\text{其中}\quad \tilde{\boldsymbol{\mu}}_t(\boldsymbol{x}_t, \boldsymbol{x}_0) := \frac{\sqrt{\bar{\alpha}_{t-1}}\,\beta_t}{1-\bar{\alpha}_t}\boldsymbol{x}_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\boldsymbol{x}_t, \tag{3}$$

$$\tilde{\beta}_t := \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t. \tag{4}$$

训练与采样伪代码见 algorithms 1 and 2。

Algorithm 1 DDPM 训练

```
repeat
    x_0 ~ q(x_0)
    t ~ Uniform({1, ..., T})
    ε ~ N(0, I)
    对 ∇_θ ‖ε − ε_θ(√ᾱ_t x_0 + √(1 − ᾱ_t) ε, t)‖^2 做梯度下降
until 收敛
```

Algorithm 2 DDPM 采样

$\boldsymbol{x}_T \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$
for $t = T, \ldots, 1$ **do**
  $\boldsymbol{z} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$（当 $t > 1$ 时），否则 $\boldsymbol{z} = \mathbf{0}$
  $\boldsymbol{x}_{t-1} = \dfrac{1}{\sqrt{\alpha_t}}\left(\boldsymbol{x}_t - \dfrac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t, t)\right) + \sigma_t \boldsymbol{z}$
end for
return $\boldsymbol{x}_0$

注 2.1. DDPM 前向过程本质上是 Wiener 过程的一个离散化版本——每一步都注入新的高斯噪声，所以**后向的一步采样也必然带有随机性**。这与 FM 的确定性演化形成鲜明对比，后文将反复用到这一点。

2.2 从 Fokker–Planck 方程看 FM 与 Diffusion 的统一

把 DDPM 与 FM 放到同一个偏微分方程（PDE）框架下比较，最自然的工具是 Fokker–Planck 方程。记 $\rho(\boldsymbol{x}, t)$ 为时刻 t 的样本密度，取吉布斯自由能形式的 Fokker–Planck 方程 [5]：

$$\frac{\partial \rho}{\partial t} = \boldsymbol{\nabla} \cdot \big(\nabla \Psi(\boldsymbol{x})\, \rho\big) + \beta^{-1}\, \Delta \rho, \qquad \rho(\boldsymbol{x}, 0) = \rho^0(\boldsymbol{x}), \tag{5}$$

其中第一项 $\boldsymbol{\nabla} \cdot (\nabla \Psi \rho)$ 对应**焓变**（由势能梯度驱动的漂移项），第二项 $\beta^{-1}\Delta\rho$ 对应**熵变**（扩散项）。对应到生成模型：

- **DDPM/Diffusion** 同时保留两项：漂移项对应数据 score 的引导，扩散项对应 Wiener 噪声；
- **Flow Matching** 只保留第一项，即去掉熵变（扩散项），只剩下一个纯粹由确定性力场驱动的连续性方程。

这正是 Lipman 等人 [1] 原文中给出的连续性方程形式：

$$\frac{\mathrm{d}}{\mathrm{d}t} p_t(\boldsymbol{x}) + \boldsymbol{\nabla} \cdot \big(p_t(\boldsymbol{x})\, \boldsymbol{v}_t(\boldsymbol{x})\big) = 0, \tag{6}$$

它给出了”向量场 $\boldsymbol{v}_t$ 生成概率路径 p_t”的充要条件（作为 PDE）。

命题 2.2 (FM 是去熵变的 Fokker–Planck)**.** *当 eq. (5) 中 $\beta^{-1} \to 0$、且取 $\boldsymbol{v}_t(\boldsymbol{x}) = -\nabla\Psi(\boldsymbol{x})$ 时，eq. (5) 退化为 eq. (6)。*

注 2.3 (势能诞生力场的直观). Proposition 2.2 的直观意义是：**势能诞生力场**，但中途没有熵变。这一设定有两个推论：

(a) 优点——可控性强、采样速度快、生成路径确定；

(b) 代价——**传播的可能性少**，因为没有随机项去探索势能面之外的状态。

代价 (b) 是本报告后续所有讨论的根源。

我们还可以从对比表（table 1）中看到，FM 原文扩展出的三种新概率路径——Conditional FM、Optimal Transport CFM、Schrödinger Bridge CFM——都是在 eq. (6) 的框架内做路径设计的变体，本质上仍属于确定性力场这一大类。

表 1: Lipman et al. 原文给出的概率路径对比（简化版）

Probability Path	$q(z)$	$\mu_t(z)$	σ_t	Cond. OT	Marg. OT
Var. Exploding (Song & Ermon, 2019)	$q(\boldsymbol{x}_1)$	$\boldsymbol{x}_1$	σ_{-t}	No	No
Var. Preserving (Ho et al., 2020)	$q(\boldsymbol{x}_1)$	$\alpha_{1-t}\boldsymbol{x}_1$	$\sqrt{1-\alpha_{1-t}^2}$	No	No
Flow Matching (Lipman et al., 2022)	$q(\boldsymbol{x}_1)$	$t\boldsymbol{x}_1$	$t\sigma - t + 1$	Yes	No
Source Conditional FM	$q(\boldsymbol{x}_0)q(\boldsymbol{x}_1)$	$t\boldsymbol{x}_1 + (1-t)\boldsymbol{x}_0$	$\sqrt{(\sigma t)^2 + 2\sigma t(1-t)}$	Yes	No
Conditional FM	$q(\boldsymbol{x}_0)q(\boldsymbol{x}_1)$	$t\boldsymbol{x}_1 + (1-t)\boldsymbol{x}_0$	σ	Yes	No
Optimal Transport CFM	$\pi(\boldsymbol{x}_0, \boldsymbol{x}_1)$	$t\boldsymbol{x}_1 + (1-t)\boldsymbol{x}_0$	σ	Yes	Yes
Schrödinger Bridge CFM	$\pi_{2\sigma^2}(\boldsymbol{x}_0, \boldsymbol{x}_1)$	$t\boldsymbol{x}_1 + (1-t)\boldsymbol{x}_0$	$\sigma\sqrt{t(1-t)}$	Yes	Yes

2.3 ”均值对均值”：两类模型神经网络记忆结构的差异

为了说清 FM 与 DDPM 的本质差异，我们给出一个极简设置：**均值对均值**。假设我们在两次抽取中拿到了（几乎）相同的高斯噪声样本与（几乎）相同的目标图像（fig. 1）。

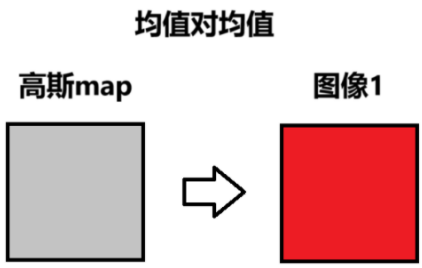

图 1: 极简设置——几乎相同的高斯样本映射到几乎相同的目标图像。无论 FM 还是 DDPM, 此时都在逼近一个**确定的 $\boldsymbol{v}_t$ 空间或 $\boldsymbol{x}_t$ 空间**。

无论采用 FM 还是 DDPM 的训练方式，在这种极限设置下，模型都会收敛到一个确定的中间量——FM 得到确定的 $\boldsymbol{v}_t$，DDPM 得到确定的 $\boldsymbol{x}_t$。也就是说，**从训练的角度，两者都在用尽可能低的损失逼近一个确定的空间**（$\boldsymbol{v}_t$ 空间或 $\boldsymbol{x}_t$ 空间）。

但两者**学习的内容**不一样：

- **FM** 直接基于高斯 map 与图像，学习得到的是**力场速度值 $\boldsymbol{v}_t$**；
- **DDPM** 基于确定的 $\boldsymbol{x}_t$ 与 t，反过来学习**导向这个 $\boldsymbol{x}_t$ 的高斯 map**。

换言之，DDPM 的反推训练直接建立了**中间样本 $\boldsymbol{x}_t$ 到起点高斯 map $\boldsymbol{x}_T$ 的映射**；在反向采样时，每一步都调用这个学习结果：利用 $\boldsymbol{x}_t$ 和 t 预测能带回起点 map 的 $\boldsymbol{\epsilon}_\theta$，再结合当前点做一步递推，得到前一步的均值（见 eq. (7)）。

$$\boldsymbol{\mu}_\theta(\boldsymbol{x}_t, t) = \tilde{\boldsymbol{\mu}}_t\left(\boldsymbol{x}_t, \frac{1}{\sqrt{\bar{\alpha}_t}}(\boldsymbol{x}_t - \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t))\right) = \frac{1}{\sqrt{\alpha_t}}\left(\boldsymbol{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t, t)\right). \tag{7}$$

注 2.4 (为什么 DDPM 不直接学习均值 $\boldsymbol{u}_t$？). 简单想一下就明白：如果网络的输入是 $\boldsymbol{x}_t$ 与 t、输出直接是 $\boldsymbol{u}_t$，我们无法建立有效的训练监督——因为这几个量全部是**局部变量**；而 DDPM 学到的起始高斯 map 是 **全局变量**。这就是 DDPM 必须绕一步去学 $\boldsymbol{\epsilon}_\theta$ 的深层原因。

注 2.5 (为什么用 UNet？). 因为 UNet 有去噪的功能——我们要去掉的，正是叠加在原始高斯 map 上的噪声，这样才能”回到起点”。

力场确定性 vs. 学习相对性。 把上述对比推到极致，可以得到本节的关键结论：

- **DDPM** 中，一个高斯 map 的输入可以得到多样的输出——因为学习是**相对的**（仅针对均值、而非实际值），而不是绝对的，所以只能一 step 一 step 学。
- **Flow Matching** 中，学习的是一个**绝对**的力场，所以一个高斯 map 的多次输入会反复得到一个**固定的输出**（参考不同数据样本得到的期望值）——这就是**力场确定性**。

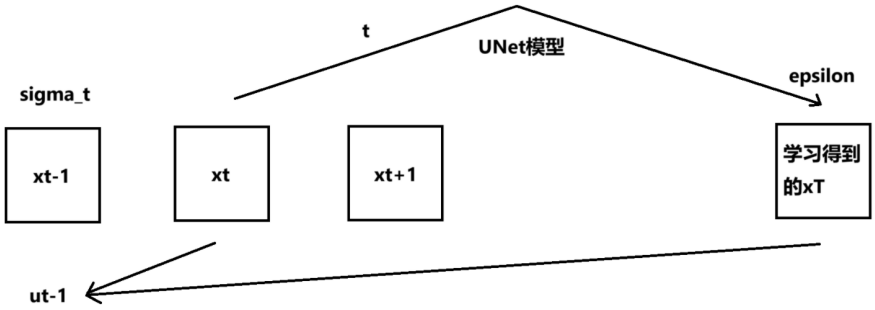

图 2: DDPM 采样过程：基于当前点 $\boldsymbol{x}_t$ 与 UNet 预测的起点 map，通过递推得到前一步均值 $\boldsymbol{u}_{t-1}$。

2.4 力场确定性的代价：方差控制问题

我们所构建的 FM 本质上是**一个确定力场的离散采样**（基于 tensor 的精度）。当我们从高斯的某个样本集合传播到目标数据域的一个样本集合时，**数据集的数据分布复杂度越强，学习时就会得到更小方差的高斯域，对应更大方差的目标数据域**。

期望值可以对应起来——然而，目标方差过大时会导致定性结果出现问题：因为糅合了差距过大的图像样本的特征的高斯 map 映射，会导致**期望值与其参考的数据之间有较大的差别**。

命题 2.6 (MSE 作为方差评估的代理)**.** *一个简单判断目标数据方差的方法是观察训练 MSE: MSE 越大，说明当前训练对应的数据样本与学习出的期望值之间的差异越大。*

不同模式的样本集合会有一定程度的重合——这就是特征融合的过程，也是生成出新内容的关键——以某个**学习出的期望值**为均值、以某种**方差**进行变化，然后得到全新的东西。问题在于，当我们要生成一个有完整结构的数据（比如人脸、人体关节序列）时，方差幅度过大就会导致：

1. **人脸**会产生缝合的、结构不自然的”鬼脸”——这是方差过大导致的**脸部结构变化不连续**；
2. **人体关节序列**会出现明显的振动——这种振动我认为来自数据集过大的随机性。

所以为了定性指标，我们不应让数据集本身体现过大的方差。结构的合理性是很难用具体的概率判据去判断的，**将方差控制在尽可能小的范围，是一个基本策略**。

2.5 实验验证

基于上述分析，我们设计了如下三个验证实验：

1. **MSE 对方差的评估作用**；
2. **数据集方差对实际定性的体现**；
3. **使用贝叶斯方式在不同子模型中大量均等抽样，能否实现 FID 下降的效果**。

其中实验 3 因为优化空间大大增加，所需时间较长，尚未出结果；本节主要报告实验 1、2 的结论。

结论 1：MSE 与训练稳定性。 MSE 在训练到 2500 轮之后下降到了 0.2+ 的量级，相比原先 475 轮全数据训练稳定在 0.6 左右，下降非常明显。这验证了 Proposition 2.6：缩小数据集方差后，模型能更紧密地拟合期望值。

结论 2：最终抽样的定性结果。 我们来看最终的抽样结果（2500 轮，fig. 3）。经过连续抽样（训练阶段）统计，**24 张图片中鬼脸个数为 0**，仅有左下一张图片比较模糊。

图 3: 2500 轮后的 CelebA 抽样结果。24 张样本中鬼脸个数为 0。

与 475 轮少量样本的对比。 作为对比，475 轮训练下的少量样本结果（fig. 4）中有大量样本存在明显的结构变形——”一缕扭曲的风吹过”，变形成鬼脸的概率较高。而 2500 轮训练下变形成鬼脸的概率极低。

(a) 475 轮训练的典型抽样样本，有鬼脸

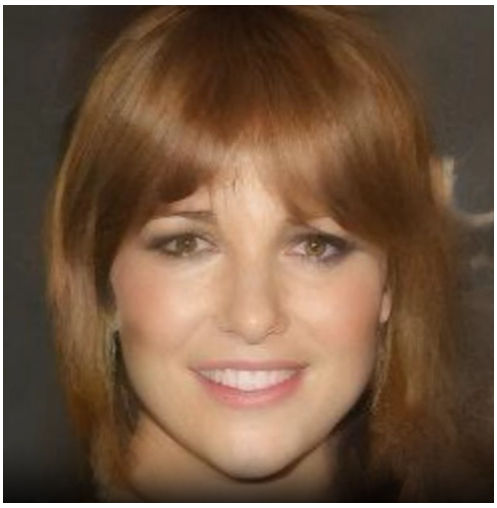

(b) 2500 轮训练的典型抽样样本，分辨率不高，但是无鬼脸。

图 4: 不同训练轮数的对比——2500 轮结果结构稳定性显著优于 475 轮。

FID 对比。 2500 轮最终 FID 为 15.9，相比原先全数据集 9.24 实际上是**上升了一个量级**（变差了）——毕竟部分数据集是有偏的，这里通过均等抽取出 bias 即可。这正是本文开头论点的实证：**FID 下降不等于定性更好**，本实验的定性结果（无鬼脸）显著优于基线，但 FID 反而变高了。

2.6 子系统分割：方差控制的策略推广

上述实验我认为可以验证两点：(i) 定性实验的方差必须控制在一个足够小的范围内；(ii) 控制方差最简单的方法就是缩小数据集。

这里有**子系统**的概念，因为同一个高斯样本、同一个力场，没有办法把整个数据集的特征做很好的融合——期望值附近的邻域太大了，我认为就不是合理的邻域了，尤其对于脸部这样变化细微的数据任务。

定义 2.7 (子系统分割)**.** 将单个生成任务拆分成多个力场进行生成，每个力场对应一个小方差的数据子集。在采样阶段，通过贝叶斯方式在多个子力场之间选择或融合。

注 2.8. 子系统分割的作用也可以从**有条件生成**（文生姿态）中体现出来——本质上只要缩小数据集、然后看定性的可视化就可以看出结果。因为本身就是服务于定性，所以只要从诸多定性结果中抽取一个最合理的即可。

分隔为 8 份时，第一份和第二份分别训练——不一致但合理，两个通道得到的结果

3 结论

本报告从 Fokker–Planck 方程出发，揭示了 Flow Matching 的**力场确定性**是它相对于 Diffusion 模型最本质的特征——既是工程优势的来源，也是定性问题的根源。通过”均值对均值”的极简分析，说明 FM 与 DDPM 的神经网络分别记忆了**力场速度**与 **起点高斯 map**，这两种记忆结构导致了采样时的绝对性与相对性差异。力场确定性在数据方差过大时会引发结构不连续的鬼脸问题；最直接的控制方法是缩小数据集，更一般的策略是将单个任务分割为多个子系统。

参考文献

[1] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le. Flow Matching for Generative Modeling. In *ICLR*, 2023.

[2] J. Ho, A. Jain, and P. Abbeel. Denoising Diffusion Probabilistic Models. In *NeurIPS*, 2020.

[3] Y. Song and S. Ermon. Generative Modeling by Estimating Gradients of the Data Distribution. In *NeurIPS*, 2019.

[4] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler, and S. Hochreiter. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium. In *NeurIPS*, 2017.

[5] R. Jordan, D. Kinderlehrer, and F. Otto. The Variational Formulation of the Fokker–Planck Equation. *SIAM Journal on Mathematical Analysis*, 29(1):1–17, 1998.

[6] C. Villani. *Optimal Transport: Old and New.* Springer, 2009.